



# Relatório Gerencial

Roteirização Preditiva & Digital Twin

Documento gerado em: 2026-04-30 11:18:50.789727




# Relatório Gerencial de Roteirização Preditiva

Eduardo Lopes Jonker *Disciplina: Sistemas Inteligentes | UDESC* Gerado em:  
2026-04-30 11:18:50.789727

Este documento consolida os resultados do sistema de roteirização preditiva, utilizando inteligência de dados para otimização logística.


## 1. Análise Preditiva de Demanda

### 1.1. Projeção de Volume (30 Dias)




**Insight Chave:** O volume total previsto para os próximos 30 dias é de **50,353 unidades**. **Acurácia (MAPE):** 5.07% (Média de Erro Percentual Absoluto).

## 1.2. Sazonalidade e Componentes



A análise de componentes permite identificar picos semanais e o impacto de feriados, permitindo um planejamento de frota muito mais assertivo.

### 1.3. Projeção de Longo Prazo (120 Dias)



---

## Diferenciais de Inovação (Inteligência Avançada)

### Sustentabilidade (ESG)

O modelo agora integra o impacto ambiental na priorização.

**Impacto Ambiental:**



### Resiliência e Monitoramento de Drift

**Monitoramento de Anomalias:**

---

## 2. Otimização e Priorização Logística (IPL)

O **Índice de Prioridade Logística (IPL)** normaliza volume, criticidade de serviço, performance e custos logísticos.




**Insight Chave:** A cidade prioritária é **CURITIBANOS**, com um IPL de **0.80**.

### 3. Planejamento de Suprimentos (Troca de Toners)

Estimativa baseada na capacidade de 10000 cópias por suprimento.

| Cidade         | Volume Anual Previsto | Trocas de Toner Anual |
|----------------|-----------------------|-----------------------|
| FLORIANÓPOLIS  | 102536                | 10.25                 |
| BLUMENAU       | 97221                 | 9.72                  |
| ITAJAÍ         | 73110                 | 7.31                  |
| CHAPECÓ        | 69870                 | 6.99                  |
| CRICIÚMA       | 55189                 | 5.52                  |
| JARAGUÁ DO SUL | 47768                 | 4.78                  |
| LAGES          | 40606                 | 4.06                  |
| BRUSQUE        | 36037                 | 3.60                  |
| TUBARÃO        | 25796                 | 2.58                  |
| CONCÓRDIA      | 17953                 | 1.80                  |

## 4. Análise Financeira e Viabilidade (ROI)



**Conclusão Financeira:** A simulação de Monte Carlo com **10,000,000 iterações** indica uma economia média de **43.61%** no custo operacional.

## 5. Avaliação de Decisão: Matriz de Confusão

| Previsão      | Realidade     | Classificação | Impacto                            |
|---------------|---------------|---------------|------------------------------------|
| Alta Demanda  | Alta Demanda  | ✓ VP          | Sucesso na alocação de frota.      |
| Alta Demanda  | Baixa Demanda | ✗ FP          | Desperdício de frete (ociosidade). |
| Baixa Demanda | Alta Demanda  | ✗ FN          | Quebra de SLA (atraso crítico).    |
| Baixa Demanda | Baixa Demanda | ✓ VN          | Economia validada (frota retida).  |

---

## 6. Detalhamento Técnico

### 6.1. Equação do Prophet

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

- $y(t)$  : O volume de impressões previsto no tempo  $t$ .
- $g(t)$  : A componente de tendência, representando o crescimento ou queda não-periódica.
- $s(t)$  : A componente de sazonalidade, capturando padrões periódicos (semanal, anual).
- $h(t)$  : A componente de feriados, ajustando a previsão para eventos específicos.
- $\epsilon_t$  : O termo de erro, representando variações não modeladas.

### 6.2. Snippets de Implementação

#### Treinamento do Modelo:

```
df = pd.read_csv(caminho_arquivo, sep=None, engine='python', encoding='utf-8')

# Prophet EXIGE que as colunas se chamem 'ds' (Data) e 'y' (Valor/Volume)
# Mapeamento flexível das colunas do seu sistema
col_map = {col: 'ds' for col in df.columns if 'data' in str(col).lower()}
col_map.update({col: 'y' for col in df.columns if 'volume' in str(col).lower()})

df = df.rename(columns=col_map)

# Tratamento do formato da data e de números brasileiros ("1.500,00" -> "1500.00")
df['ds'] = pd.to_datetime(df['ds'], format='%d/%m/%Y', errors='coerce')
df['y'] = df['y'].apply(lambda x: str(x).replace('.', '').replace(',', '.'))
```

#### Cálculo do IPL:

```
df_final['Logistica_Norm'] = (df_final['Dificuldade_Logistica'] - l_min) / (l_max - l_min)

# --- Inovação ESG: Cálculo de Impacto Ambiental ---
```



```

# Simula emissão de CO2 com base na dificuldade (distância/tempo) e eficiência d
df_final['Pegada_Carbono'] = df_final['Dificuldade_Logistica'] * np.random.unifo
c_min, c_max = df_final['Pegada_Carbono'].min(), df_final['Pegada_Carbono'].max(
df_final['Carbono_Norm'] = (df_final['Pegada_Carbono'] - c_min) / (c_max - c_min

# Atribuição de Peso Semântico (Baseado na Ontologia)
# Perícias possuem peso 1.5 (Urgência Social) e SEA peso 1.0
df_final['Peso_Tipo'] = df_final['Tipo'].apply(lambda x: 1.5 if 'PERICIA' in str

# Cálculo do IPL (Índice de Prioridade Logística)
# Pesos atualizados: Volume (15%), Tipo (25%), Performance (20%), Logística (20%)
df_final['IPL'] = (
    (df_final['Volume_Norm'] * 0.15) +
    (df_final['Peso_Tipo'] * 0.25) +
    (df_final['Perf_Norm'] * 0.20) +
    (df_final['Logistica_Norm'] * 0.20) +
    (df_final['Carbono_Norm'] * 0.20)
)

```

## 7. Informações do Ambiente e Auditoria

- **SO:** Linux 6.14.0-15-generic (#15-Ubuntu SMP PREEMPT\_DYNAMIC Sun Apr 6 15:05:05 UTC 2025)
- **Arquitetura:** x86\_64
- **Python:** 3.13.11
- **Host:** eduardonote-Inspiron-15-3530