

Relatório Gerencial de Roteirização Preditiva

Otimização Logística com Inteligência Artificial e
Simulação

Autor: Eduardo Lopes Jonker

Disciplina: Sistemas Inteligentes | UDESC

Gerado em: 2026-08-15 16:33:50.729972



Relatório Gerencial de Roteirização Preditiva

Autor: Eduardo Lopes Jonker

Disciplina: Sistemas Inteligentes | UDESC

Data de Geração: 2026-08-15 16:33:50.729972

Resumo Executivo: Este documento consolida os resultados do sistema de roteirização preditiva, que integra modelagem de séries temporais, análise multicritério e simulação estocástica para otimizar a logística de frotas. O objetivo é transformar dados brutos em inteligência acionável, resultando em redução de custos e aumento da eficiência operacional.

1. Fundamentação Matemática e Metodologia

O projeto rompe com a roteirização estática tradicional através de uma arquitetura preditiva baseada em três pilares matemáticos:


1.1. Modelagem de Séries Temporais (Anticipatory Routing)

Utilizamos a decomposição aditiva do algoritmo **Prophet** para prever a volumetria futura $y(t)$:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$


Onde $g(t)$ é a tendência, $s(t)$ a sazonalidade (via Séries de Fourier), $h(t)$ o impacto de feriados e ϵ_t o ruído estatístico. Esta abordagem nos permite antecipar a demanda em vez de apenas reagir a ela.

1.2. Projeção de Volume (30 Dias)





Insight Chave: O volume total previsto para os próximos 30 dias é de **50,362 unidades**.
Acurácia (MAPE): 5.06% (Erro Percentual Médio). **Erro Médio Absoluto (MAE):** 70.12 (Desvio médio em unidades).

1.3. Sazonalidade e Componentes



A decomposição permite isolar o "peso" sazonal na operação, garantindo um planejamento de frota proativo.

1.4. Planejamento Tático e Estratégico (120d e 365d)



Volume Acumulado (Anual): O sistema projeta uma demanda total de **697,281 unidades** para os próximos 12 meses.

2. Otimização e Priorização Logística (MCDA)

O **Índice de Prioridade Logística (IPL)** é o núcleo decisório deste projeto. Ele utiliza uma **Análise de Decisão Multicritério (MCDA)** para transformar variáveis de naturezas distintas em um indicador único e comparável de prioridade.

2.1. Metodologia de Normalização

Como as variáveis (volume, SLA, custo, pegada de carbono) possuem unidades diferentes, aplicamos a normalização *Min-Max* para o intervalo $[0, 1]$:

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

2.2. Composição dos Pilares

O IPL consolida cinco dimensões estratégicas para uma tomada de decisão holística: 1.



Volume Futuro (\$V_n\$): Projeção de demanda para evitar gargalos operacionais. 2.

Criticidade do Serviço (\$T_n\$): Prioridade social (Perícias têm peso superior a atendimentos SEA). 3. **Risco de SLA (\$P_n\$):** Identificação de unidades com performance em queda ($1 - \text{score}$).

4. **Dificuldade Logística (\$L_n\$):** Otimização baseada na distância e custos de deslocamento. 5. **Sustentabilidade (ESG) (\$E_n\$):** Penalização de rotas com maior impacto ambiental.

A fórmula consolidada para a tomada de decisão é:

$$IPL = (V_n \cdot w_v) + (T_n \cdot w_t) + (P_n \cdot w_p) + (L_n \cdot w_l) + (E_n \cdot w_e)$$




Insight Chave: A cidade prioritária identificada é **CURITIBANOS**, com score **0.55**, indicando o maior risco de rompimento de serviço se não atendida no próximo ciclo.

3. Análise Financeira e Viabilidade (ROI)


A prova de conceito econômica utiliza simulações de Monte Carlo ($N=1,000,000$) para validar o ROI sob incerteza. O custo otimizado C_{opt} é modelado como:

$$C_{\text{opt}} = C_{\text{base}} \cdot \text{Fator_Cidades} \cdot (1 - \text{Economia_Rota})$$



Conclusão Financeira: A simulação indica uma economia média esperada de **43.61%** no custo operacional logístico.

3.1. Eficiência Sustentável e Governança (ESG)




O modelo não apenas otimiza o capital, mas reduz o impacto ambiental de forma proporcional, gerando um "ROI Verde" através da eliminação de rotas de baixa prioridade.

Análise de Carbono:

3.2. Auditoria de Dados com Aprendizado Não Supervisionado

Além da análise preditiva, o sistema utiliza **Aprendizado Não Supervisionado** (Isolation Forest) para auditar a integridade dos dados e detectar comportamentos atípicos.



Resultado da Auditoria:

Monitoramento de Anomalias:



Análise de Escalabilidade: Ecossistema Santa Catarina

O sistema demonstra robustez matemática para a gestão integral do contrato estadual: * **Ativos Monitorados:** 6.580 impressoras. * **Capilaridade:** 2.930 locais em 295 municípios. * **Tese Científica:** A utilização de **Clusterização Geográfica Hierárquica** permite a redução da dimensionalidade do problema em 90%. Ao aplicar o IPL como critério de seleção de nós (*Node Selection*), o sistema converte um TSP estático massivo em um **Selective VRP** dinâmico, garantindo escalabilidade para infraestruturas críticas estaduais.

4. Contribuições Científicas e Inovação

Este projeto avança em relação à literatura clássica de otimização ao introduzir três diferenciais de fronteira:

- 1. **Roteirização Preditiva (Anticipatory VRP):** Transição da logística reativa para um modelo que antecipa a demanda futura (`yhat` do Prophet), resolvendo a latência operacional ao focar em *onde a demanda estará amanhã*.
- 2. **Heurística de Decisão Multicritério (MCDM):** Ao contrário de métodos que usam apenas distância, o **Índice de Prioridade Logística (IPL)** consolida métricas heterogêneas (Volume, Risco de SLA, Criticidade) em um tensor matemático unificado. Na prática, converte o TSP genérico em um **Prize-Collecting TSP** orientado ao valor do negócio.
- 3. **Tradução Epistemológica de Erro Estatístico:** A adaptação da Matriz de Confusão para a área de logística de frota, demonstrando empiricamente o custo de cada erro algorítmico (ex: Falso Positivo = desperdício de frete; Falso Negativo = multa por quebra de SLA).

5. Planejamento de Suprimentos e Gastos Multitemporais

Cidade	Vol. Anual	Toners	Custo/Pág (Méd)	Custo Anual	Árvores
FLORIANÓPOLIS	113017	11.30	R\$ 3,616.53		
BLUMENAU	107159	10.72	R\$ 3,429.07		
ITAJAÍ	80583	8.06	R\$ 2,578.66		
CHAPECÓ	77011	7.70	R\$ 2,464.36		
CRICIÚMA	60830	6.08	R\$ 1,946.57		
JARAGUÁ DO SUL	52651	5.27	R\$ 1,684.82		
LAGES	44757	4.48	R\$ 1,432.21		
BRUSQUE	39720	3.97	R\$ 1,271.04		

Cidade	Vol. Anual	Toners	Custo/Pág (Méd)	Custo Anual	Árvores
TUBARÃO	28433	2.84	R\$ 909.85		
CONCÓRDIA	19789	1.98	R\$ 633.24		

Resumo de Custos Projetados: - **Projeção Mensal (30 dias):** R\$ 1,611.59 - **Projeção Trimestral (120 dias):** R\$ 6,659.70 - **Projeção Semestral (180 dias):** R\$ 10,252.00 - **Projeção Anual (365 dias):** R\$ 22,312.99

6. Impacto Ambiental e Consciência Ecológica

Como elemento de análise de desperdício, o sistema quantifica o impacto em árvores (Base: 7.500 folhas/árvore):

- **Impacto Mensal:** 6.71 árvores.
- **Impacto Anual:** 92.97 árvores.

7. Avaliação de Decisão: Matriz de Confusão Logística

Previsão	Realidade	Classificação	Impacto
Alta Demanda	Alta Demanda	✓ VP	Sucesso na alocação de frota.
Alta Demanda	Baixa Demanda	✗ FP	Desperdício de frete (ociosidade).
Baixa Demanda	Alta Demanda	✗ FN	Quebra de SLA (atraso crítico).
Baixa Demanda	Baixa Demanda	✓ VN	Economia validada (frota retida).

8. Auditoria e Reprodutibilidade

8.1. Snippets de Implementação

Treinamento do Modelo:

```
if not os.path.exists(caminho_arquivo):
    print(f"⚠️ Aviso: Base de dados '{caminho_arquivo}' não encontrada. Utilizando simulador.")
    return simular_historico_impressoes()

print(f"Lendo base de dados pré-processada: {caminho_arquivo}")
df = pd.read_csv(caminho_arquivo)
df['ds'] = pd.to_datetime(df['ds'])
df['y'] = pd.to_numeric(df['y'], errors='coerce').fillna(0)
df = df.dropna(subset=['ds', 'y']).sort_values(by='ds')
return df

except Exception as e:
    print(f"❌ Erro ao ler os dados reais ({e}). Utilizando simulador como fallback.")
```

Cálculo do IPL:

```
# Atribuição de Peso Semântico (Baseado na Ontologia)
# Perícias possuem peso 1.5 (Urgência Social) e SEA peso 1.0
df_final['Peso_Tipo'] = df_final['Tipo'].apply(lambda x: 1.5 if 'PERICIA' in str(x).upper() else 1.0)
# Normaliza o tipo para o intervalo [0, 1] para manter a consistência do IPL
df_final['Tipo_Norm'] = (df_final['Peso_Tipo'] - 1.0) / (1.5 - 1.0)

# Cálculo do IPL (Índice de Prioridade Logística)
# O IPL é uma Análise de Decisão Multicritério (MCDA) que converte variáveis heterogêneas em uma única métrica.
# Pesos: Volume (15%), Tipo/Criticidade (25%), Performance/SLA (20%), Logística/Custo (20%), Carbono (20%)
df_final['IPL'] = (
    (df_final['Volume_Norm'] * 0.15) +
    (df_final['Tipo_Norm'] * 0.25) +
    (df_final['Perf_Norm'] * 0.20) +
    (df_final['Logistica_Norm'] * 0.20) +
    (df_final['Carbono_Norm'] * 0.20)
)
```

```
with open('esg_impacto.txt', 'w') as f:
    f.write(f"Redução estimada de emissões otimizada: {df_final['Pegada_Carbono'].mean()}\n")
```

9. Informações do Ambiente e Auditoria

- **SO:** Linux 6.14.0-15-generic (#15-Ubuntu SMP PREEMPT_DYNAMIC Sun Apr 6 15:05:05 UTC 2025)
- **Arquitetura:** x86_64
- **Python:** 3.13.11
- **Host:** eduardonote-Inspiron-15-3530