

Relatório Gerencial de Roteirização Preditiva

Otimização Logística com Inteligência Artificial e
Simulação

Autor: Eduardo Lopes Jonker

Disciplina: Sistemas Inteligentes | UDESC

Gerado em: 2026-08-15 21:51:20.125040

Relatório Científico Automatizado: Roteirização Preditiva

Autor: Eduardo Lopes Jonker

Data de Geração: 2026-08-15 21:51:20.125040

Abstract

Este relatório apresenta um sistema de roteirização logística inteligente que transcende a otimização de rotas clássica. A metodologia integra modelagem preditiva de séries temporais (Prophet), análise de decisão multicritério (MCDA) e otimização de rotas (TSP) para criar um framework de **Roteirização Preditiva Antecipatória**. O sistema não apenas minimiza a distância, mas maximiza o valor do negócio ao priorizar dinamicamente os nós da malha logística com base em um **Índice de Prioridade Logística (IPL)**. A validação econômica é realizada por meio de Simulações de Monte Carlo, e a robustez dos dados é auditada por algoritmos de detecção de anomalias. O resultado é um Gêmeo Digital para gestão de frotas, capaz de reduzir custos operacionais e a pegada de carbono da operação.

1. Introdução

O Problema do Caixeiro Viajante (TSP) é um dos desafios mais emblemáticos da otimização combinatória. Soluções tradicionais, no entanto, tratam o problema de forma estática, assumindo que a necessidade de visita é binária e o único custo é a distância. Em cenários logísticos reais, a decisão de *qual cidade visitar* é dinâmica e multifacetada.

Este trabalho propõe uma solução híbrida que transforma o TSP clássico em um problema de roteirização preditiva e orientada a valor. A inovação central reside na criação do **Índice de Prioridade Logística (IPL)**, uma métrica que converte o problema de "qual a rota mais curta?" para "qual a rota de maior valor para o negócio?".

2. Metodologia Proposta

A arquitetura do sistema é um pipeline modular onde a saída de cada etapa alimenta a subsequente.

2.1. Modelagem Preditiva com Prophet

Utilizamos o algoritmo Prophet para modelar a série temporal de volume de impressões. A natureza aditiva do Prophet decompõe a série em tendência, sazonalidade e feriados:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Onde: - $g(t)$: Tendência de crescimento ou queda. - $s(t)$: Padrões periódicos (semanal, anual). - $h(t)$: Efeito de feriados. - ϵ_t : Termo de erro (ruído).

A saída, **yhat**, representa a demanda *esperada*, permitindo uma roteirização antecipatória.




Gráfico 1: Projeção de demanda para os próximos 30 dias com intervalo de confiança.

Acurácia (MAPE): 5.18% (Erro Percentual Médio).

2.2. Índice de Prioridade Logística (IPL)

O IPL é o núcleo decisório do sistema, utilizando uma Análise de Decisão Multicritério (MCDA) para fundir variáveis heterogêneas em um único score de prioridade. Cada variável é normalizada (Min-Max) e então ponderada:

$$IPL = \sum_{i=1}^n w_i \cdot V_{i,norm}$$

Os pesos w_i representam a importância estratégica de cada variável V_i (Volume, Criticidade, Performance, Custo Logístico, ESG).




Gráfico 2: Ranking de cidades por prioridade de roteirização (IPL).

2.3. Otimização de Rota (TSP)

Com as cidades priorizadas pelo IPL, o problema é reduzido a um TSP clássico. A implementação atual utiliza uma abordagem heurística em duas fases: 1. **Nearest Neighbor (NN)**: Uma heurística construtiva e gulosa que gera uma rota inicial de boa qualidade em tempo $O(n^2)$. 2. **2-opt**: Uma heurística de melhoria local que refina a rota do NN, removendo cruzamentos de arestas até atingir um ótimo local.

3. Análise Comparativa de Estratégias para o TSP

A escolha do algoritmo para resolver o TSP é um trade-off entre a qualidade da solução e o tempo computacional. A tabela abaixo compara a abordagem do projeto com outras estratégias da literatura.

Categoria	Algoritmos Exemplo	Garantia de Otimidade	Complexidade e Aplicação
Métodos Exatos	Branch-and-Bound, Concorde	Sim, encontra a solução ótima.	Exponencial ($O(2^n)$). Inviável para problemas com mais de algumas dezenas de cidades.
Heurísticas Construtivas	Nearest Neighbor (NN), Inserção Mais Distante	Não. Soluções 15-25% piores que a ótima.	Polinomial ($O(n^2)$). Muito rápido, ideal para gerar soluções iniciais. (Usado no projeto)
Heurísticas de Melhoria Local	2-opt, 3-opt, Lin-Kernighan (LKH)	Não, encontra ótimos locais.	Polinomial ($O(n^2)$ a $O(n^3)$). Rápido e eficaz para refinar rotas. (2-opt usado no projeto)
Meta-heurísticas	Simulated Annealing (SA), Algoritmos Genéticos (GA), Ant Colony (ACO)	Não. Projetadas para escapar de ótimos locais.	Iterativas e estocásticas. Mais lentas, mas com potencial para soluções de altíssima qualidade.
Aprendizado de Máquina	Reinforcement Learning (RL), GNNs	Não. Aprendem políticas a partir dos dados.	Inferência rápida, mas treinamento caro. Generalização é um desafio ativo de pesquisa.

Justificativa da Abordagem Adotada

A combinação **Nearest Neighbor + 2-opt** foi escolhida por oferecer um excelente balanço entre simplicidade, velocidade e qualidade da solução para o escopo do problema (18 cidades). Para problemas de maior escala (centenas de cidades), uma evolução natural seria usar algoritmos

mais robustos como o **Lin-Kernighan-Helsgaun (LKH)** ou bibliotecas especializadas como o **Google OR-Tools**.

4. Resultados e Discussão

4.1. Validação Econômica (Simulação de Monte Carlo)

Para validar o impacto financeiro, uma simulação de Monte Carlo com $N=1,000,000$ iterações foi executada. A simulação compara o custo operacional de um cenário "reativo" com o custo do modelo preditivo otimizado.




Gráfico 3: Distribuição de probabilidade de custos, comparando o cenário atual com o modelo otimizado.

Conclusão Financeira: A simulação indica uma economia média esperada de **43.61%** no custo operacional logístico.

4.2. Auditoria de Dados com Isolation Forest

O sistema utiliza o algoritmo **Isolation Forest** para auditar a integridade dos dados e detectar comportamentos atípicos que poderiam distorcer a priorização.




Gráfico 4: Detecção de anomalias no cruzamento de Volume vs. IPL.

Resultado da Auditoria: O algoritmo Isolation Forest identificou 2 cidades com comportamento atípico no cruzamento de Volume vs Logística.

5. Variações do Problema: do TSP ao VRP

O TSP é a base, mas problemas logísticos reais frequentemente se manifestam como o **Problema de Roteamento de Veículos (VRP)**, que generaliza o TSP para múltiplos veículos. O projeto já contém uma estrutura inicial para essa evolução (`main_vrp.py`). Futuras integrações podem incluir:

- **CVRP (Capacitated VRP):** Veículos com capacidade de carga limitada.
- **VRPTW (VRP with Time Windows):** Clientes com janelas de tempo para visita.
- **DVRP (Dynamic VRP):** Novos pedidos surgem em tempo real, exigindo re-roteirização.

6. Conclusão

Este trabalho demonstrou com sucesso a implementação de um sistema de roteirização preditiva que supera as limitações do TSP tradicional. Ao integrar modelagem de séries temporais e análise de decisão multicritério, o sistema transforma a otimização logística de um problema puramente geométrico para uma decisão estratégica orientada a valor. A abordagem heurística (Nearest Neighbor + 2-opt) provou ser altamente eficaz para o escopo do problema, com baixo custo computacional. Os resultados financeiros e de performance reforçam que a verdadeira inovação na logística moderna não está apenas em encontrar a rota ótima, mas em prever e priorizar de forma inteligente *quais paradas devem compor essa rota*.

Apêndice: Informações de Auditoria